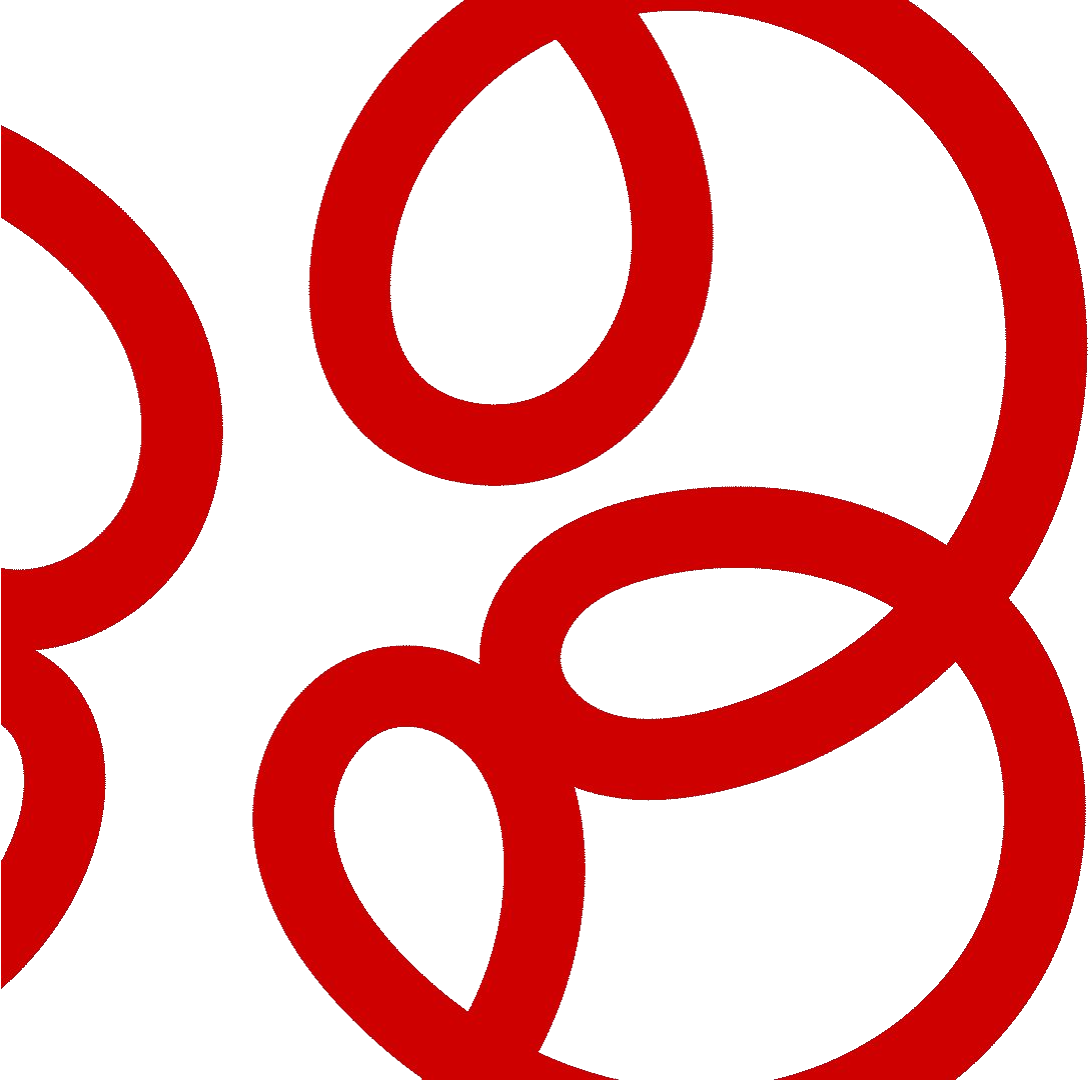


تجربه‌ی سرو مدل‌های open-weight در دیوار

مهر ۱۴۰۵ - لینوکس فست امیرکبیر

فهرست

۱ استفاده از ai در محصول

۲ نیاز به ارزیابی

۳ ساخت مدل‌های زبانی کوچک

۴ قطعی‌های اینترنت

۵ اینفرنس چطوری انجام می‌شه؟

۶ گلوگاه‌ها



ساخت محصول‌های مبتنی بر هوش مصنوعی

از دو سال پیش شروع به ساخت محصول‌های aiای کردیم



دستیار خرید و فروش



بررسی آگهی



پیشنهاد دسته‌بندی هنگام ثبت

1:49

ثبت آگهی

صفحهٔ ۱ از ۳: تصاویر و توضیحات

عکس آگهی *



افزودن عکس

عنوان آگهی *

فروش خودنویس ژاپنی

توضیحات آگهی *

اصل خودم از ژاپن آوردم. قیمت مناسب

بعدی

1:49

ثبت آگهی

صفحهٔ ۲ از ۳: دسته و ویژگی‌ها

دسته و محل آگهی

دسته * لوازم التحریر

پس از ثبت، دستهٔ آگهی قابل ویرایش نیست.

مکان آگهی * انتخاب

ویدیوی آگهی

افزودن ویدیو

ویژگی‌ها

نوع کالا * انتخاب

رنگ

وضعیت * انتخاب

بعدی

چی رو بهینه کنیم؟

چی رو بهینه کنیم؟



هزینه

چی رو بهینه کنیم؟



هزینه



سرعت (لیتنسی)

چی رو بهینه کنیم؟



هزینه



سرعت (لیتنسی)



کیفیت

چطوری مقایسه کنیم؟



سیستم دسته‌بندی
« ب »



سیستم دسته‌بندی
« الف »



ارزیابی!

کلید حل ماجرا

تشکیل تیم Evaluation & Fine tune

ساخت روش‌های ارزیابی

آموزش مدل‌ها

سرو مدل‌ها

هر سه فاکتور عوض شدن!

تروپوت ۵۰ به جای ۷۰ به جای ۱۲۰

لیتنسی ۱۰۰۰ به جای ۲۵۰

کیفیت ۹۲ به جای ۹۷



قطعی اینترنت

بازی کلا عوض شد


Transformers


vLLM

[Perf] CFS-aware torch thread count in set_default_torch_num_threads #34462

Code

Closed Meshkati wants to merge 4 commits into `vllm-project:main` from `Meshkati:fix/cfs-aware-omp-num-threads`

Conversation 20 Commits 4 Checks 5 Files changed 3 +245 -2

Meshkati commented on Feb 13

Purpose

In containers/Kubernetes pods with CFS CPU limits, Python's `os.cpu_count()` returns the **host** CPU count, not the pod's actual limit. `set_default_torch_num_threads()` in `vllm/utils/torch_utils.py` defaulted to `1` when `OMP_NUM_THREADS` was unset — correct for GPU-heavy serving but it ignores the actual CPU budget available to the container for input-processing work.

This PR makes that default CFS-aware.

What this PR does

1. Adds `vllm/_cpu_detection.py`

A lightweight utility module (no torch dependency) that detects container CPU limits via cgroup CFS quota files:

Priority	Source
1	cgroup v2: `/sys/fs/cgroup/{cgroup_path}/cpu.max`
2	cgroup v1: `cpu.cfs_quota_us / cpu.cfs_period_us`
3	`os.sched_getaffinity(0)` (cpuset-aware)
4	`os.cpu_count()` (bare-metal fallback)

`get_available_cpus()` is `lru_cache`d — cgroup quota doesn't change during process lifetime.

2. Updates `set_default_torch_num_threads()` in `vllm/utils/torch_utils.py`

Reviewers
- bigPYJ1151
- ywang96
- 2 more reviewers
  - phiott
  - gemini-code-assist[bot]

Assignees
No one assigned

Labels
cpu stale

Projects
None yet

Milestone
No milestone

Development
Successfully merging this pull request may close these issues.
None yet

Notifications Customize

مهندسی یعنی سبک سنگین کردن

سخت‌افزار ثابته
سه تا عدد داریم

هر چی از یکی بگیری به یکی دیگه می‌دی

مهندسی یعنی سبک سنگین کردن

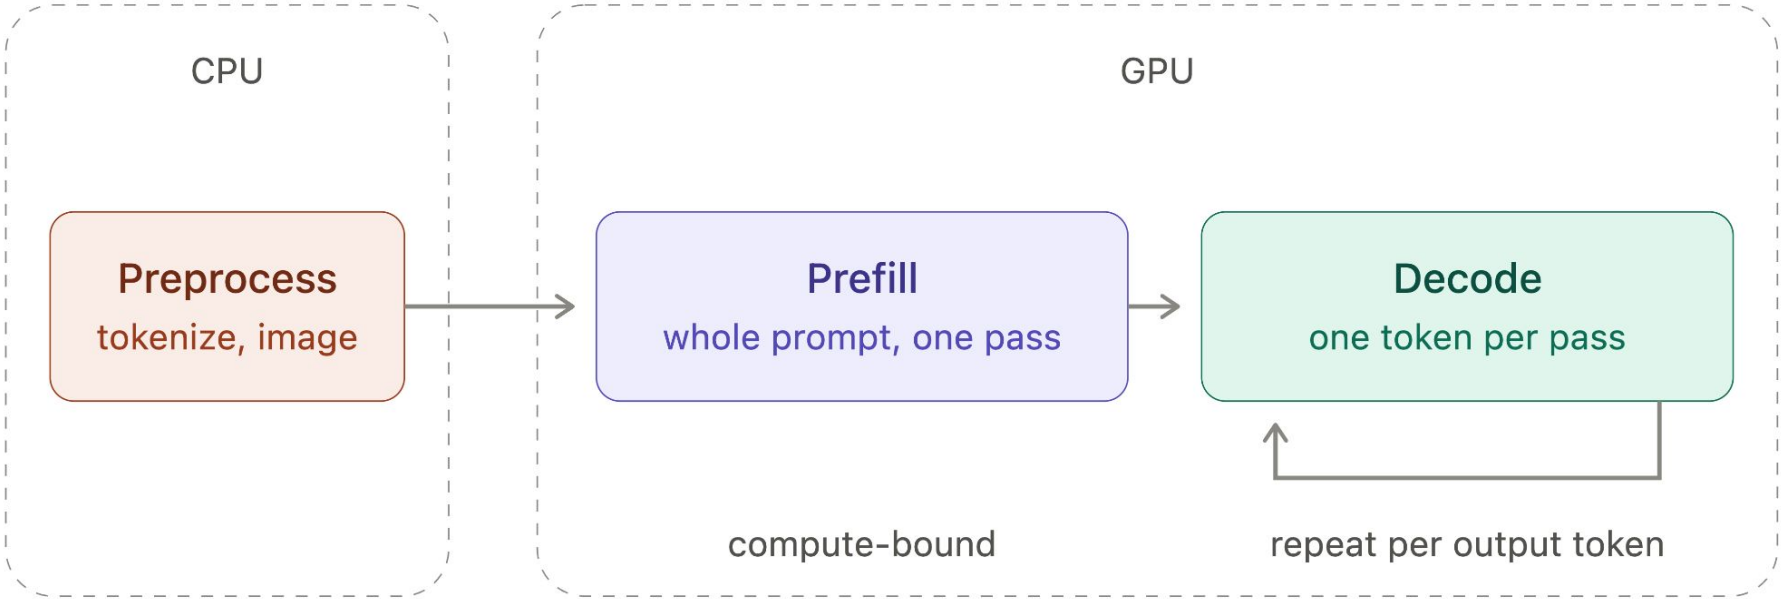
پس باید بفهمیم سیستم
چطوری کار می‌کنه!



اینفرنس

یه ریکوئست چه مسیری رو می‌ره؟


قیمت
این
گوشی
خیلی
?
tokens so far
LLM
one forward pass, all layers
مناسبه
62%
بالاست
25%
قدیمیه
9%
pick one, append it, run the whole thing again — one token per loop

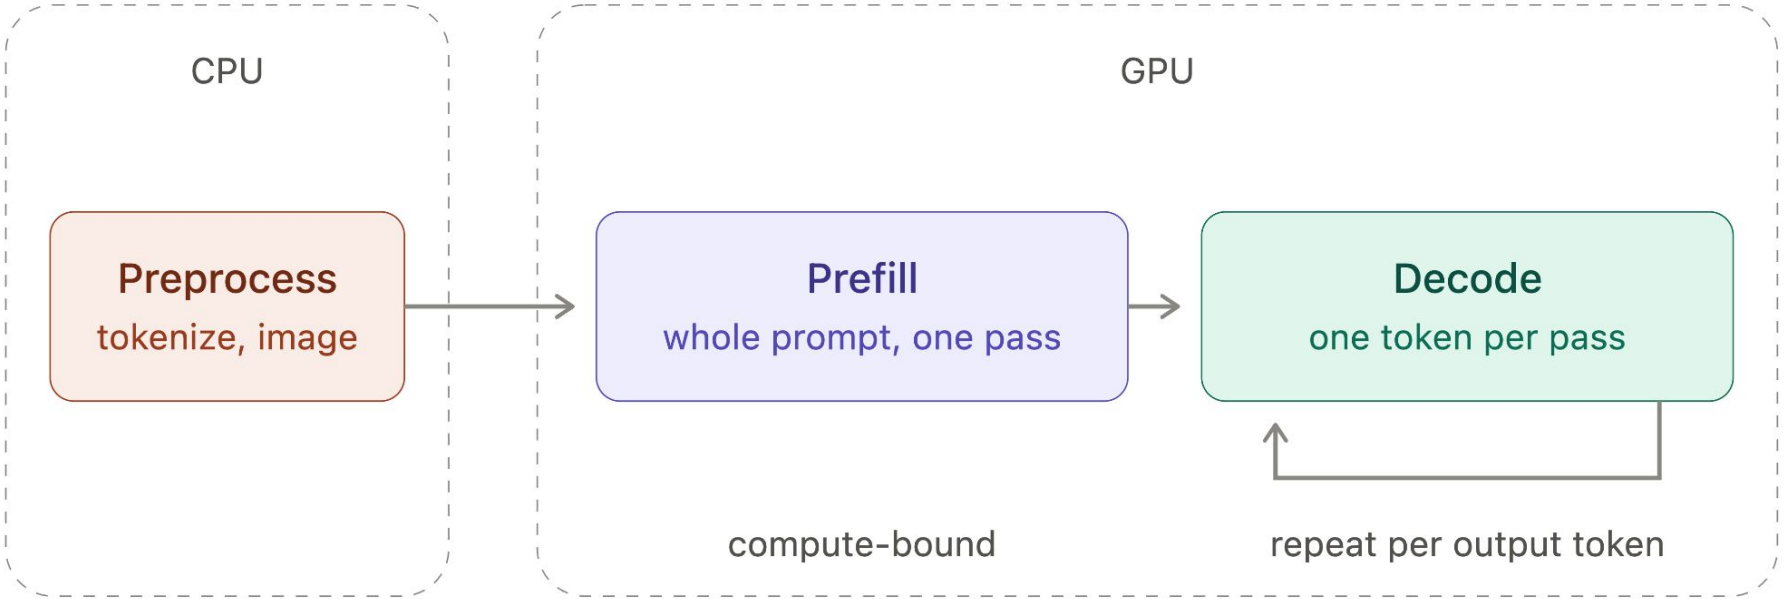

CPU
GPU
Preprocess
tokenize, image
Prefill
whole prompt, one pass
Decode
one token per pass
compute-bound
repeat per output token

گلوگاه اول

بررسی آگهی با عکس

CPU Time

از ۵۰ به ۷۰ رسیدیم

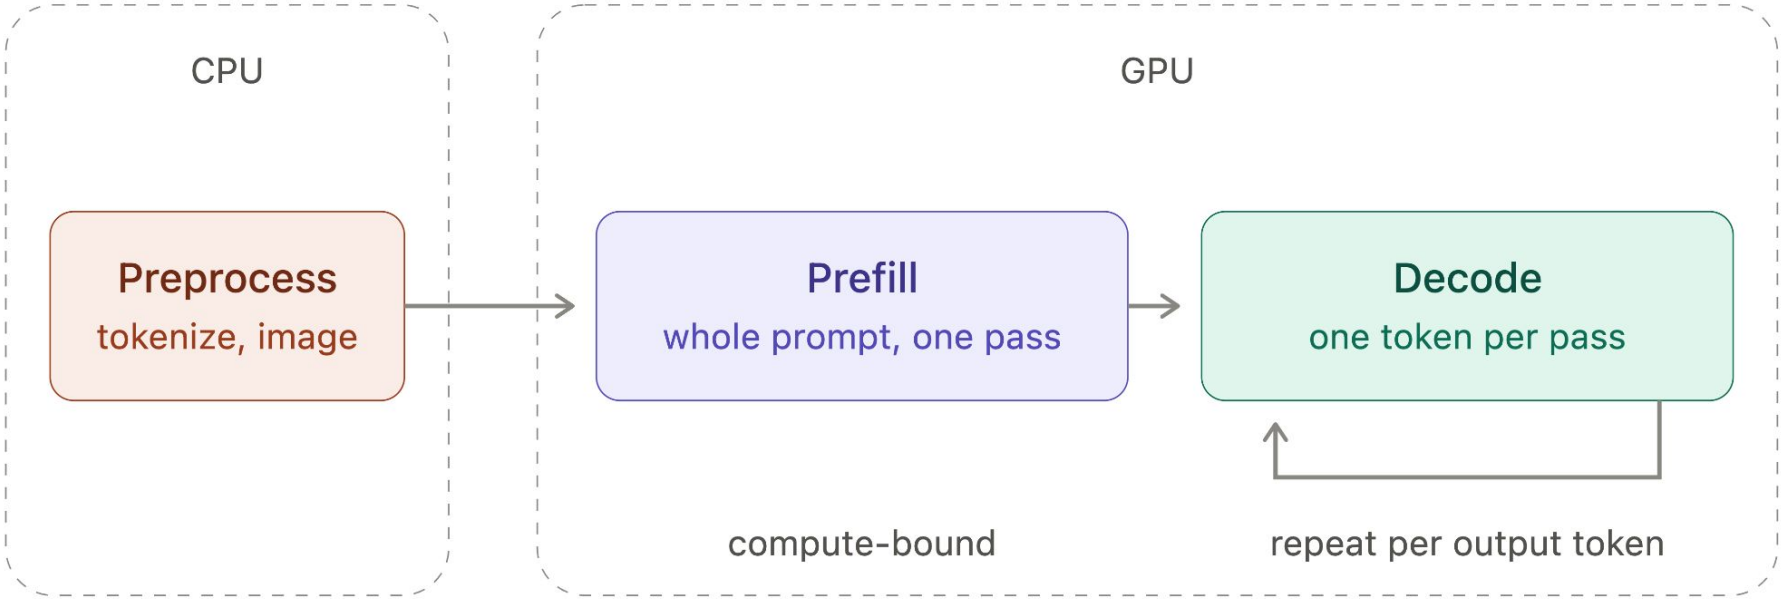

CPU
GPU
Preprocess
tokenize, image
Prefill
whole prompt, one pass
Decode
one token per pass
compute-bound
repeat per output token

گلوگاه دوم

بچ کردن درخواست‌ها

GPU Compute Bound

از ۷۰ به ۱۲۰ رسیدیم



Prefill builds the KV cache; decode is memory-bandwidth-bound and idles the GPU unless batched

گلوگاه سوم

بی‌کار ماندن GPU برای مدل‌های کوچک

از ۱۲۰ به ۶۰۰ رسیدیم



Learn about Netflix's world class engineering efforts, company culture, product developments and more.

Following

Netflix + AI + LLM + Platform Engineering + Model Serving +

In-House LLM Serving at Netflix



Netflix Technology Blog Following 10 min read · Jul 17, 2026

976 17 14

By AI Platform's Model Runtime team and Inference team

Introduction

Most organizations consume LLMs through hosted APIs. Netflix went further — we run the full stack ourselves, from model deployment through inference, inside our existing production environment rather than a separate ML silo. Some of those decisions weren't obvious, and a few revealed their trade-offs only under production load.

Top highlight

This post focuses on the choices where alternatives were seriously

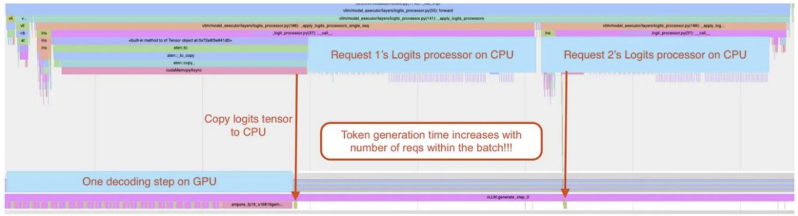


Figure 2: Logits processor serial execution on CPU with vLLM V0

vLLM V1 enabled a batch-level design

The structural fix arrived in vLLM V1, which moved logits processing to batch level. We rewrote our custom processor to operate on batch-level data structures, computing masks across many requests together, and reimplemented the hot path in C++ with multi-threading to step around the GIL. The V1 API requires explicit tracking of batch membership changes via update_state(batch_update) — more complex than V0's per-request interface, but necessary to maintain correct state in a dynamically evolving batch. Figure 3 shows logits processing time staying flat as batch size grows.

1



فهرست

۱ استفاده از ai در محصول

۲ نیاز به ارزیابی

۳ ساخت مدل‌های زبانی کوچک

۴ قطعی‌های اینترنت

۵ اینفرنس چطوری انجام می‌شه؟

۶ گلوگاه‌ها

دمتون
گرم!